

数据挖掘与机器学习课后作业

凌彬

信管2302

202321116055

数据回归方法的基本方法、步骤；

- 1.收集一组包含因变量 (Y) 和自变量(X)的数据；
- 2.选定因变量和自变量之间的模型，即一个数学式子，利用数据按照一定准则（如：最小二乘法、极大似然估计、损失函数法等）计算模型中的系数；
- 3.利用统计分析方法（方差等）对不同的模型进行评估比较，找出效果最好的模型；
- 4.判断得到的模型是否适合于这组数据；
- 5.利用模型对因变量作出预测或解释。

一元线性回归基本数学模型

设 Y 是一个可观测的随机变量,它受到一个非随机变量因素 x 和随机误差 ε 影响。若 Y 与 x 有如下线性关系:

$$Y = \beta_0 + \beta_1 x + \varepsilon$$

且 ε 的均值 $E(\varepsilon) = 0$, 方差 $\text{var}(\varepsilon) = \sigma^2 (\sigma > 0)$, 其中 β_0 、 β_1 是固定的未知差数, 称为回归系数, Y 称为因变量, x 称为自变量, 则称此 Y 与 x 之间的函数关系表达式为一元线性回归模型。

对于实际问题, 要建立回归方程, 首先要确定能否建立线性回归模型, 其次确定如何对模型中的未知参数 β_0 、 β_1 进行评估。

通常, 我们首先对总体 (x, Y) 进行 n 次独立观测, 获得 n 组数据 (称为样本观测值):

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

然后在直角坐标系 xOy 中画出数据点 $(x_i, y_i), (i = 1, 2, \dots, n)$, 该图形称为数据的散点图。如果这些点大致地位于同一条直线的附近, 或者说, 散点图呈现线性形状, 则认为 Y 与 x 之间的关系符合线性关系。此时, 利用最小乘法可以得到回归模型参数 β_0 、 β_1 的最小二乘估计 $\hat{\beta}_0$ 、 $\hat{\beta}_1$, 估计公式为:

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \bar{x} \hat{\beta}_1 \\ \hat{\beta}_1 = \frac{L_{xy}}{L_{xx}} \end{cases}$$

$$\text{其中, } \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, L_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, L_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})。$$

于是就可以建立经验模型:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

多元线性回归基本数学模型

设 Y 是一个可观测的随机变量, 它受到 $p(p > 0)$ 个非随机变量因素 $X_1, X_2, \dots, X_p$ 和随机误差 ε 的影响。若 Y 与 $X_1, X_2, \dots, X_p$, 有如下线性关系:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

其中, $\beta_0, \beta_1, \beta_2, \dots, \beta_p$ 是固定的未知参数, 称为回归系数; ε 是均值为 0、方差为 $\sigma^2 (\sigma > 0)$ 的随机变量; Y 称为被解释变量; $X_1, X_2, \dots, X_p$ 称为解释变量。此模型称为多元线性回归模型。

自变量 $X_1, X_2, \dots, X_p$ 是非随机的且可精确观测, 随机误差 ε 代表其随机因素对因变量 Y 产生的影响。

对于总体 $(X_1, X_2, \dots, X_p; Y)$ 的 n 组观测值 $(x_{i1}, x_{i2}, \dots, x_{ip}; y)(i = 1, 2, \dots, n; n > p)$, 应满足式:

$$\begin{cases} y_1 = \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \dots + \beta_p x_{1p} + \varepsilon_1 \\ y_2 = \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \dots + \beta_p x_{2p} + \varepsilon_2 \\ \dots \\ y_n = \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2} + \dots + \beta_p x_{np} + \varepsilon_n \end{cases}$$

其中 $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$, 相互独立, 且设 $\varepsilon_i \sim N(0, \sigma^2) (i = 1, 2, \dots, n)$, 记

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

则模型可用矩阵形式表示为:

$$Y = X\beta + \varepsilon$$

其中, Y 称为观测向量; X 称为设计矩阵; β 称为待估计向量; ε 是不可观测的 n 维随机向量, 它的分量相互独立, 假定 $\varepsilon \sim N(0, \sigma^2 I_n)$ 。

Logistic回归的基本数学模型，Logistic回归方法的含义，特点，与普通一元线性回归、多元线性回归的联系与区别

Logistic回归的基本数学模型

在回归分析中，因变量 y 可能有两种情形：① y 是一个定量的变量，这时就用通常的 regress 函数对 y 进行回归；② y 是一个定性的变量，比如 $y = 0$ 或 1 ，这时就不能用通常的 regress 函数对 y 进行回归，而是使用所谓的 Logistic 回归。Logistic 方法主要应用在研究某些现象发生的概率 p ，比如股票涨还是跌，公司成功或失败的概率。除此之外，本章还讨论概率 p 与哪些因素有关。Logistic 回归模型的基本形式为：

$$p(Y = 1 | x_1, x_2, \dots, x_k) = \frac{\exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}{1 + \exp(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}$$

其中， $\beta_0, \beta_1, \dots, \beta_k$ 为类似于多元线性回归模型中的回归系数。

Logistic回归方法的含义

理解 Logistic 回归的含义，关键在于明白它为什么要叫“回归”，做的却是“分类”的事，以及它内部的数学逻辑。

1. 从“概率”的角度理解

它的本质是计算“属于某类”的概率。现实世界中，很多事情我们无法 100% 确定，只能谈可能性。比如：

“这封邮件是垃圾邮件的概率有多大？”

“这个病人患有糖尿病的概率有多大？”

Logistic 回归就是用来做这件事的。它根据输入的特征 X ，计算出一个介于 0 和 1 之间的概率值 P 。

2. 从“决策边界”的角度理解

虽然它输出的是概率，但最终做分类判断时，需要一个明确的界限。通常会设定一个阈值（默认通常是 0.5）：

如果 $P \geq 0.5$ ，则预测为类别 1（正例）。

如果 $P < 0.5$ ，则预测为类别 0（负例）。

这就相当于在特征空间中画了一条线（对于一元是点，对于二元是直线，对于高维是超平面），这条线就是决策边界。Logistic 回归本质上是在寻找一个能够最好地分隔两类样本的线性边界。

Logistic回归方法的含义

3. 从“对数几率”的角度理解（数学本质）
正如前文所述，Logistic 回归可以写成：

$$\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 X$$

这个公式揭示了它的统计本质：它假设“对数几率”与特征 X 之间存在线性关系。这使得 Logistic 回归虽然解决了分类问题，但其背后依然有着坚实的统计学线性模型基础，这也是它名字里保留“回归”二字的原因。

Logistic回归方法的特点

(1)优点

1.输出具有自然概率解释：它不仅仅告诉你“是”或“否”，还能告诉你“有多大的把握是”，这一点在很多需要风险评估的场景中非常宝贵。

2.实现简单，计算高效：模型形式简洁，训练（通常使用梯度下降或牛顿法）和预测的速度都很快，计算资源消耗低。

3.可解释性强：这是它相比神经网络等“黑盒”模型的最大优势之一。通过观察系数 β ，我们可以直接判断特征 X 对结果的影响方向和程度。

- 如果 $\beta_1 > 0$ ，表示 X 越大， Y 属于类别 1 的概率越大。

- 系数绝对值越大，表示该特征的影响力越大。

正则化易用：很容易通过加入 L1 或 L2 正则化项来防止过拟合，尤其是在特征维度很高的时候。

对线性关系拟合良好：如果数据的决策边界确实是线性的，Logistic 回归往往能表现得很出色。

(2)缺点

1.容易欠拟合，精度有限：它的决策边界是线性的（一条直线或一个平面），如果数据在特征空间中的分布不是线性的（比如环形分布、月牙形分布），Logistic 回归将难以准确分类，导致欠拟合。

2.对特征工程依赖性强：由于模型本身比较“简单”（线性模型），它无法自动发现复杂的特征交互关系。因此，需要人工进行充分的特征工程（如创建多项式特征、交互项），将非线性关系转换成线性关系，才能提升模型效果。

3.对异常值敏感：虽然比古老的感知机好一些，但严重的异常值仍然可能对模型的决策边界产生较大影响。

Logistic回归和一元、多元线性回归联系与区别

对比维度	一元线性回归	多元线性回归	Logistic 回归
因变量 Y 类型	连续数值型	连续数值型	二分类离散型 (0/1、是 / 否)
预测目标	预测具体数值大小	预测具体数值大小	预测属于某一类的概率
输出范围	$(-\infty, +\infty)$	$(-\infty, +\infty)$	$(0, 1)$
核心公式	$Y = \beta_0 + \beta_1 X + \epsilon$	$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p + \epsilon$	$P(Y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p)}}$
函数形式	线性直接输出	线性直接输出	线性 + Sigmoid 激活
损失函数	最小二乘法 (MSE)	最小二乘法 (MSE)	对数似然 / 交叉熵损失
假设条件	线性、正态分布、同方差、独立	同一元线性回归	不要求 Y 正态分布，允许非线性边界
典型应用	身高→体重、时间→产量等单变量预测	多因素预测房价、销售额等	疾病诊断、违约预测、用户是否点击 / 购买
能否做分类	不能 (强行用会不合理)	不能	专门用于二分类

第六章 “回归” 读书笔记

第6章围绕回归分析展开，核心是通过寻找最佳拟合趋势线实现预测，同时量化不同预测变量对结果的影响。回归分析从单变量趋势线（如用房间数预测房价）入手，通过添加更多预测变量并赋予最优权重，可显著提升预测精度，其中权重的大小对应变量影响的强弱，比如波士顿房价案例中，周围低收入居民占比的影响大于房间数。为求解这些最优权重（即回归系数），文中介绍了梯度下降法，其原理是通过迭代调整权重以最小化预测误差，类似逐步走向山底的过程，随机梯度下降法则通过随机选取单个样本迭代，可避免复杂模型中陷入局部最优的问题。回归系数需结合变量标准化解读，标准化后才能公平对比不同变量的影响，而单变量场景下，标准化回归系数即为相关系数，其取值范围在-1到1之间，可反映变量与结果的关联方向和强度。回归分析虽易用、直观且计算快速，但存在明显局限性，它对异常值敏感，易受多重共线性影响导致权重失真，仅能拟合线性趋势，且无法证明变量间的因果关系，需结合业务逻辑和数据预处理规避这些问题。总体而言，回归分析是常用的预测工具，在预测变量无强相关性、无异常值且趋势为线性的场景下效果最佳，核心价值在于可解释性和变量影响量化。

第 6 章 回归分析

6.1 趋势线

趋势线是预测时常用的工具，它们很容易生成，也很容易理解。只要翻阅每天的报纸，就会看到大量趋势线图表，涉及的主题各种各样，从股票价格到天气预报。

一般的趋势线只涉及单个预测变量，这个变量用来产生预测结果。比如使用时间（预测变量）预测一家公司的股票价格（预测结果）。不过，通过添加更多预测变量，可以改善预测结果，比如除了时间之外，还使用销售收入来一起预测股票价格。


回归分析 不但可以通过考虑更多预测变量改善预测结果，而且还可以比较各个预测变量的强弱。

为了理解回归分析的原理，让我们看一个预测房价的例子。

6.2 示例：预测房价

本示例使用的是 20 世纪 70 年代美国波士顿房价的相关数据及预测量。经过初步分析发现，对房价影响最大的两个因素是房间数以及周围低收入居民所占的比例。

从图 6-1 可以看出，价格较高的房子通常房间数较多。为了预测房价，我们画了一条趋势线（图中的蓝线）。这条趋势线亦称最佳拟合线，大部分数据点都分布在这条线附近。由此预测，一所拥有 8 个房间的房子售价大约是 38 150 美元。



6.3 梯度下降法

在回归分析中，预测变量的权重是主要参数，通过解方程就可以直接求得最优权重。不过，由于回归分析简单并且适用于阐释概念，因此我们将用它来解释另外一个优化参数的方法。这个方法就是**梯度下降法**，一般在无法直接得到参数时使用。

简单地说，梯度下降法先初步猜测合适的权重组合，再通过一个迭代过程，把这些权重应用于每个数据点做预测，然后调整权重，以减少预测误差。

这个过程类似于一步步走向山底下。每走一步，梯度下降法都要判断从哪个方向下是最陡峭的，然后朝着那个方向重新校准权重。最终，会到达最低点，这个点的预测误差最小，图 6-4 描绘了一条经过优化的回归趋势线如何与梯度上的最低点相对应。




图 6-4 趋势线通过梯度下降法达到最优化

除了回归之外，梯度下降法也能用来优化其他模型中的参数，比如第 8 章讲的支持向量机和第 11 章讲的神经网络。然而，在这些更为复杂模型中，梯度下降法的结果可能会受到“下山起点”（即初始参数值）的影响。比如，假设起点下方恰好有一个小凹坑，那么梯度下降法可能会将其误认为是最优点，如图 6-5 所示。

6.4 回归系数

在为回归预测变量求得最佳权重之后，需要对它们进行解释。

回归预测变量权重的正式名称是**回归系数**，它表示某个预测变量相比于其他预测变量的影响大小，换言之，它表示相关预测变量的增加值，而非绝对预测强度。

举例来说，如果使用房屋的建筑面积和房间数来预测房价，那么房间数的权重也许可以忽略不计，因为房间数在衡量房屋大小方面的作用与建筑面积有重叠，所以它对整个预测能力的贡献很小。

预测变量的度量单位不同也会影响对回归系数的解释。比如，对于同一个预测变量，以米为度量单位时的权重是以厘米为度量单位时的 100 倍。为了避免这个问题，应该在做回归分析之前先对预测变量的度量单位进行标准化。标准化类似于统一使用百分位数来表示每个变量，经过标准化之后，预测变量的系数被称为**标准化回归系数**，可以**用来衡量更准确的比较**。

在预测房价的例子中，两个预测变量（房间数和周围低收入居民所占比例）都经过了标准化，权重比为 2.7 : 6.3。这意味着在预测房价时，周围低收入居民所占比例比房间数起更大的作用。回归方程如下所示。

$$\text{房价} = 2.7(\text{房间数}) - 6.3(\text{低收入居民所占比例})$$

请注意，在这个方程中，低收入居民所占比例的权重前面有一个负号，这表示权重为负。这是因为该预测变量和房价是负相关关系，这一点可以从图 6-2 中向下倾斜的趋势线看出来。

6.5 相关系数

当只存在一个预测变量时，该**预测变量的标准化回归系数也被称为相关系数**，记作 r ，如图 6-6 所示。相关系数的取值范围为 -1 到 1，它提供了两个信息。




图 6-6 不同的相关系数下数据的分布情况

- **关联方向**：相关系数为正表示预测变量和结果变化的方向一致；为负则表示两者变化方向相反。房价和房间数是正相关关系，和周围低收入居民所占比例是负相关关系。
- **关联强度**：值越接近 -1 或 1，预测变量的作用度越大。例如，图 6-1 中趋势线表示的相关系数是 0.7，而图 6-2b 中的是 -0.8，这意味着在预测房价时，相比于房间数，周围低收入居民所占比例起着更大的作用。若 r 值为 0，则表示预测变量和结果之间不存在关系，因为相关系数表示单个预测变量的绝对强度，所以相比于回归系数，相关系数在对预测变量进行排序时更可靠。

6.6 局限性

虽然回归分析能够提供丰富的信息，并且计算速度快，但是它本身存在着一定的局限性。

- **对异常值敏感**：由于回归分析平等地对待所有的数据点，因此只要存在几个有异常值的数点，就会给趋势线造成很大的影响。为了避免出现这种情况，在做进一步分析之前，可以先使用散点图找出异常值。
- **造成糟糕的预测变量权重失真**：如果回归模型包含高度相关的预测变量，那么这些变量的权重会失真，这就是所谓的**多重共线性**问题。为了解决这个问题，可以在分析之前先把相关预测变量剔除，或者使用更高级的技术，比如**套索回归**或**岭回归**。
- **弯曲的趋势**：在本章所举的例子中，趋势由直线表示，但是有些趋势可能是可弯曲的。对于这种情况，可能需要在预测变量的值进行替换，或者使用支持向量机（详见第 8 章）等其他算法。
- **并不总是存在因果联系**：假设我们发现房价和房价是正相关关系，我们知道**房价不会让房子增值**，但是**那些将得起购的家庭往往会有较高的收入**，并且很有可能住在房价较高的社区。

尽管回归分析有上述局限性，但是它仍然是做预测时最常用、最易用、最直观的一种技术。仔细理解分析结果，有助于确保结论的准确性。

6.7 小结

- 回归分析用于寻找最佳拟合线，使得尽可能多的数据点位于这条线附近（或这条线上）。
- 趋势线由带权重的组合预测变量得到。这些权重被称为回归系数，表示某个预测变量相对于其他预测变量的影响强度。
- 在下面几种情况下，回归分析的效果最好：

(1) 预测变量之间的关系不强；

(2) 无异常值；

(3) 趋势可用直线表示。