

数据挖掘与机器学习课后作业 (5)

凌彬
信管2302
202321116055

1.整理资料：有关关联选股的背景知识（参考本页备注）

关联选股是一种基于股票间关联性的投资策略，核心是挖掘分析股票市场中不同标的的内在联系，构建模型筛选具有潜在投资价值的股票组合，区别于传统单因子选股的孤立分析，其核心逻辑源于市场非完全独立性——股票通过产业链、行业、投资者行为等渠道相互影响，这种关联蕴含着市场对行业前景、公司竞争力等因素的综合判断，且历史关联模式在一定条件下具有延续性，能用于预测价格走势，同时基于关联构建的组合可有效分散非系统性风险。关联选股的理论支撑源于多种金融市场理论与数据挖掘技术，有效市场假说认为市场价格反映所有可用信息，而关联关系正是信息传递的重要渠道；行为金融学揭示的投资者非理性导致的市场异象，让关联选股可捕捉投资者行为的传染效应；套利定价理论指出股票收益由多风险因子驱动，关联关系可视为隐含风险因子，复杂网络理论则将股票市场视为复杂系统，节点位置决定股票表现，统计套利理论则为关联选股识别价格偏离、捕捉套利机会提供了依据，同时关联规则挖掘、聚类分析、图神经网络、协整理论等数据挖掘与机器学习技术，为关联关系的识别和建模提供了技术支撑。股票关联关系主要分为基本面、价格、信息、资金四类，基本面关联是公司经营活动的实质性联系，如同产业链上下游、同行业竞争等；价格关联基于历史价格数据的统计相关性，如股价同步波动；信息关联源于信息传播渠道，如新闻共现、分析师共同覆盖；资金关联则基于资金流动，如机构抱团持股，按关联强度可分为强、中、弱三类，分别对应不同的相关系数范围。关联关系的识别可通过统计方法和机器学习方法，统计方法包括相关性分析、协整检验、格兰杰因果检验等，机器学习方法则涵盖无监督学习的聚类、关联规则挖掘，监督学习的图神经网络，以及文本挖掘的新闻共现、情绪分析等。关联选股的经典策略有配对交易、板块联动、产业链关联、关联规则选股等，广泛应用于量化投资、风险控制、事件驱动、资产配置等场景，具有系统化、纪律化、风险分散等优势。其发展历程经历了早期依赖传统统计方法、成长阶段融合大数据与机器学习、成熟阶段依托深度学习与多模态分析的演进，技术上实现了从静态到动态关联建模的突破。当前关联选股面临关联不稳定性、数据质量与维度、过拟合、市场效率提升等挑战，未来将向动态关联建模、多模态关联融合、AI驱动关联发现、关联风险控制等方向发展。总体而言，关联选股突破了传统孤立分析的局限，随着技术发展向智能化演进，成为量化投资的重要工具，投资者需结合自身情况，结合传统分析方法合理运用，构建稳健投资体系。

2.分析数据（清楚说明矩阵行与列的含义）

1. 行（Row）的定义与含义

数学定义：矩阵中沿水平方向（横向）排列的元素集合，本矩阵共 10 行，对应行标识T1~T10。

业务含义：每一行代表一个独立的交易 / 观测事务（Transaction），可以理解为「一次选股事件、一个投资组合、一个交易日的行业持仓 / 涨跌事件」等。
行内的1表示：该事务包含 / 涉及对应列的行业；
行内的0表示：该事务不包含 / 不涉及对应列的行业。
例如T1行：[1,1,0,0,1,0]，代表该事务涉及银行、券商、医药 3 个行业，不涉及钢铁、能源、化工。

2. 列（Column）的定义与含义

数学定义：矩阵中沿垂直方向（纵向）排列的元素集合，本矩阵共 6 列，对应列标识银行、券商、钢铁、能源、医药、化工。
业务含义：每一列代表一个独立的行业维度（Item / 特征），是关联选股中用于挖掘行业间关联关系的核心分析对象。
列内的1表示：对应行的事务包含该行业；
列内的0表示：对应行的事务不包含该行业。
例如银行列：[1,0,1,1,0,0,1,1,1,1]，统计可得银行行业在 10 个事务中出现了 7 次，是高频行业。

表 6-4 股票行业关联事务矩阵

	银行	券商	钢铁	能源	医药	化工
T1	1	1	0	0	1	0
T2	0	0	0	1	0	1
T3	1	1	1	0	0	0
T4	1	1	0	1	0	1
T5	0	0	1	0	1	0
T6	0	1	1	0	0	0
T7	1	0	1	0	0	0
T8	1	1	1	0	1	1
T9	1	1	1	0	0	0
T10	1	1	0	1	0	0

行业关联关系挖掘（Apriori 关联规则视角）

基于事务矩阵，可挖掘行业间的强关联规则（支持度、置信度）：

（1）强关联组合（高频共现）

银行 ↔ 券商：

共现次数：6 次（T1、T3、T4、T8、T9、T10），支持度 = $6/10=60\%$

置信度：银行→券商= $6/7\approx85.7\%$ ，券商→银行= $6/7\approx85.7\%$

解读：大金融板块高度绑定，银行上涨时券商同步上涨 / 配置的概率极高，是关联选股的核心联动组合。

银行 ↔ 钢铁：

共现次数：4 次（T3、T7、T8、T9），支持度 = 40%

置信度：银行→钢铁= $4/7\approx57.1\%$ ，钢铁→银行= $4/5=80\%$

券商 ↔ 钢铁：

共现次数：4 次（T3、T6、T8、T9），支持度 = 40%

置信度：券商→钢铁= $4/7\approx57.1\%$ ，钢铁→券商= $4/5=80\%$

解读：钢铁行业出现时，券商同步出现的概率极高，周期股与券商股联动性强。

（2）弱关联 / 互斥组合

能源 ↔ 钢铁：共现 0 次，支持度 = 0% ，属于互斥组合，即两个行业几乎不会同时出现在同一投资事务中。

医药 ↔ 能源：共现 0 次，支持度 = 0% ，同样为互斥组合，防御类与周期类行业配置分化明显。

化工 ↔ 钢铁：仅 T8 共现 1 次，支持度 = 10% ，弱关联。

3. 事务特征分析（行维度分析）

全行业覆盖事务：仅 T8 行[1,1,1,0,1,1]，覆盖银行、券商、钢铁、医药、化工 5 个行业，是唯一覆盖多数行业的事务，可用于跨行业关联分析。单一 / 双行业事务：T2（能源 + 化工）、T5（钢铁 + 医药）、T6（券商 + 钢铁）、T7（银行 + 钢铁），事务行业集中度高，适合挖掘细分行业联动。大金融主导事务：T1、T3、T9、T10，以银行 + 券商为核心，叠加其他行业，是市场主流投资结构。

3.运行程序（使用python，参考压缩文件包中的程序）

]:

	加湿器	吸尘器	吹风机	咖啡机	平板电脑	微波炉	打印机	投影仪	摄像头	无线鼠标	...	烤箱	电动牙刷	电风扇	电饭煲	硬盘	移动电源	空气炸锅	笔记本电脑	蓝牙耳机	路由器
0	False	False	False	False	False	True	False	False	False	False	...	False	False	False	False	False	False	False	True	False	False
1	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	True	False	False	False
2	False	False	False	False	False	True	False	False	False	False	...	False	False	True	False	False	False	False	False	False	False
3	True	False	False	True	False	False	False	False	False	False	...	False	False	False	False	False	False	False	False	False	False
4	False	False	True	False	True	False	False	False	False	False	...	False	False	False	False	False	False	False	False	True	False
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
95	False	True	False	False	False	False	False	False	False	True	...	True	False	False	False	False	False	False	False	False	False
96	False	False	False	False	False	False	False	False	False	False	...	False	False	False	False	False	False	True	False	False	False
97	False	False	False	False	False	False	False	False	False	False	...	True	False	False	False	True	False	False	False	False	False
98	False	False	False	True	False	False	False	False	False	True	...	False	False	False	False	True	False	False	False	False	False
99	False	False	True	False	False	True	True	False	False	False	...	False	False	False	False	False	False	False	False	False	False

100 rows × 25 columns

3.运行程序（使用python，参考压缩文件包中的程序）

jupyter 使用apriori构建商品知识图谱 Last Checkpoint: 25 minutes ago

File Edit View Run Kernel Settings Help

 Code

```
frequent_itemsets['length'] = frequent_itemsets['itemsets'].apply(len)
```

```
[6]: ## 步骤5: 过滤结果 (保留出现2次以上的2项集)
```

计算实际出现次数

```
frequent_itemsets['count'] = (frequent_itemsets['support'] * len(transactions)).astype(int)
qualified = frequent_itemsets[(frequent_itemsets['length'] == 2) & (frequent_itemsets['count'] > 1)]
```

```
[7]: qualified
```

[7]:	support	itemsets	length	count
25	0.02	[加湿器, 咖啡机]	2	2
26	0.02	[加湿器, 打印机]	2	2
27	0.02	[加湿器, 摄像头]	2	2
28	0.02	[智能手机, 加湿器]	2	2
29	0.03	[智能手表, 加湿器]	2	3
...	...	...	...	...
103	0.03	[笔记本电脑, 硬盘]	2	3
104	0.02	[硬盘, 蓝牙耳机]	2	2
105	0.02	[硬盘, 路由器]	2	2
106	0.04	[笔记本电脑, 路由器]	2	4
107	0.02	[蓝牙耳机, 路由器]	2	2

83 rows x 4 columns


[8]: #%% 步骤6: 构建知识图谱

```
G = nx.Graph()
```

添加节点 (所有出现过的商品)

```
all_products = list(te.columns_)
```

```
G.add_nodes_from(all_products)
```



4.分析结果，思考教材分析过程的含义（并指出教材中的错误）

•分析结果

基于 Apriori 算法对交易数据开展关联规则挖掘，得出商品间的频繁共 现组合。通过知识图谱可视化呈现，清晰展示不同商品间的关联强弱与聚类情况。数码、家电类商品关联性较强，常被同时购买，形成明显的关联群体。部分商品购买行为独立，与其他商品关联度较低。

• 教材分析过程含义

完整演示 Apriori 算法全流程，通 过「事务矩阵→频繁项集→强关联规则」，挖行业 - 热点 - 个股的联 动规律，为关联选股提供算法支撑。核心是将市场关联量化为数据，通过逐层搜索 + 剪枝，提取稳定有效的投 资逻辑，实现选股的自动化、科学化。

• 教材中的错误

阈值不明确：未给出支持度、置信 度的科学取值方法，仅用固定示例。结果无验证：未对关联规则做回测， 无法证明实际选股有效性。