

多元线性回归作业解答

问题分析与代码实现

观察数据集的特征

01 数据集属性全景解析

数据集共包含 5 个核心属性，涵盖投入成本、地域信息与最终收益，构建了完整的商业分析维度，为后续建模提供了多视角的数据支撑。

分类变量：State (X4)

代表公司总部所在城市，包含 New York、California、Florida 三个类别，是影响利润的关键非数值因素。

连续变量：投入成本维度 (X1-X3)

包括 R&D Spend（研发支出）、Administration（管理支出）、Marketing Spend（市场支出），反映企业在核心运营环节的资金投入规模。

02 可视化分析策略建议



箱线图：洞察利润分布特征

通过箱线图展示不同城市利润的离散程度，清晰识别中位数、四分位数及异常值，判断各城市利润的稳定性与波动区间，为异常数据处理提供依据。



条形图：对比城市平均利润水平

利用条形图直观呈现各城市的平均利润差异，快速定位利润表现最优/最差的城市区域，辅助判断地域因素对最终收益的实际影响权重。

问题2：分类变量转化为One-Hot编码



01. LabelEncoder 标签数字化

将无序的分类文本（如“巴黎、伦敦、东京”）映射为连续的数字标签（0、1、2），为后续数值化处理建立基础。



02. OneHotEncoder 生成独热编码

为每个类别创建独立的二进制列，用“1”表示样本属于该类别，“0”表示不属于，避免数值标签带来的顺序误导。



03. 规避虚拟变量陷阱 (Dummy Trap)

删除生成的n个虚拟变量中的一列（通常为第一列），消除多重共线性，确保模型参数可被正确估计。

Python Implementation

1. 导入必要的工具库

```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder  
from sklearn.compose import ColumnTransformer
```

2. LabelEncoder 将文本转为数字标签 (第4列)

```
labelencoder = LabelEncoder()  
X[:, 3] = labelencoder.fit_transform(X[:, 3])
```

3. OneHotEncoder 实现独热编码，保留其他列

```
ct = ColumnTransformer([('encoder', OneHotEncoder(), [3])],  
                        remainder='passthrough')  
X = np.array(ct.fit_transform(X))
```

4. 删除第一列以避免虚拟变量陷阱

```
X = X[:, 1:]
```

问题3：评估结果 - R^2

01. 什么是 R^2 （决定系数）？



核心定义

衡量回归模型拟合优度的核心指标，用于量化模型对数据规律的捕捉能力。



实际含义

表示因变量的变异中，可以由自变量解释的比例。 R^2 越接近1，模型对数据的拟合程度越好。

取值范围：**[0, 1]**——0代表模型完全无法解释，1代表模型完美拟合。

02. 计算实现与结果分析

在完整数据集上计算模型的 R^2 得分

```
R2 = regressor.score(X, Y)
```

```
print("模型的决定系数  $R^2$  为: ", R2)
```



本案例结果： $R^2 \approx 0.95$

这意味着模型能够解释约 95% 的因变量（利润）变化，说明我们的回归模型对数据的拟合效果非常好，具有很高的预测可信度。

问题4：系数和截距

bi = regressor.coef_ # 系数（权重，代表各特征对结果的影响程度）
b0 = regressor.intercept_ # 截距（当所有特征为0时的基准预测值）

Profit = 42989.01 + 0.7788 × R&D + 0.0294 × Admin + 0.0347 × Marketing
该方程量化了各投入要素与最终利润之间的线性关系，系数代表每单位投入带来的利润增量。

 截距 b0

42,989.01

 系数 bi

[0.7788, 0.0294, 0.0347]

 核心驱动因素

R&D系数最大(0.7788)，说明研发投入对利润的拉动作用最显著，是利润增长的关键。

 次要影响因素

行政管理系数最小(0.0294)，表明当前阶段行政投入对利润的直接贡献相对有限。

问题5：分类变量对多元线性回归的影响

01 / 分类变量带来的核心挑战

虚拟变量陷阱（多重共线性）

若有 n 个类别却设置 n 个虚拟变量，会导致完全共线性，使模型无法求解。正确做法是仅设置 $n-1$ 个虚拟变量。

基础差异与模型复杂度提升

不同类别（如城市）会带来基础截距的差异，且编码过程增加了变量维度；同时分类变量可能与其他连续变量产生复杂的交互效应。

02 / 本案例的实操处理策略



标准化编码：采用独热编码 (One-Hot)

将分类特征的每个类别映射为二进制向量，实现定性变量的量化转换，便于模型识别类别信息。



规避陷阱：主动删除冗余列

对编码后的虚拟变量删除一列，消除完全共线性问题，确保回归系数估计的有效性和唯一性。

最终简化策略： 尽管完成了分类变量的编码处理，但为了降低模型复杂度、提升解释性，本案例最终选择仅保留数值型变量进行多元线性回归建模。

问题6: Label化 vs One-Hot编码

01. 直接Label化（0/1/2）的典型误区



序关系错误：引入虚假层级

模型会错误地认为类别间存在“ $0 < 1 < 2$ ”的大小顺序，而城市、颜色等无序分类本无高低之分。



数值含义错误：误导特征权重

数字编号的大小会被模型解读为“价值”的高低，导致模型对编号较大的类别分配不合理的高权重。

02. One-Hot编码的核心优势



无偏表示：独立二进制特征

为每个类别创建独立的0/1特征列，让每个类别在特征空间中地位平等，不存在数值上的大小关联。



适配性强：完美兼容线性模型

线性回归、逻辑回归等模型能正确识别并计算每个类别对结果的独立影响，避免距离度量的数学错误。

核心结论：对于城市、性别、品牌等无序分类变量，严禁直接使用LabelEncoder的数字编号，必须采用 One-Hot 编码进行特征处理，以确保模型训练的准确性。