

基于大数据挖掘与机器学习的二手车价 格预测研究

实验报告

小组成员：凌彬，王俊超，谢雨

目录

一、绪
论.....1

1.1 行业研究背景.....1

1.2 研究核心问题.....2

1.3 数据基础与研究难点.....2

1.4 研究内容与预期成果.....3

二、数据预处
理.....4

2.1 缺失值处理.....4

2.2 极端值处理.....4

2.3 特征工程与冗余剔除.....5

2.4 分类特征编码.....5

2.5 数据集划分与质量复检.....6

三、数据探索性分
析.....7

3.1 描述性统计分析.....7

3.2 数据分布与异常值分析.....7

3.3 变量相关性分析.....8

3.4 特征分组差异分析.....8

3.5 探索性分析总结.....9

四、模型构建与实验设
计.....10

4.1 建模整体方案.....10

4.2 对照实验设计.....11

4.3 基准线性模型构建.....11

4.4 集成学习模型构建.....12

五、模型评估与对比分

析.....	13
5.1 核心评估指标释义.....	13
5.2 多模型性能分项评估.....	13
5.3 模型综合对比分析.....	14
5.4 预处理效果验证.....	15
六、特征分析与聚类应用.....	16
6.1 特征重要性分析.....	16
6.2 关键特征深度分析.....	17
6.3 K-means 聚类模型构建.....	17
6.4 聚类结果与业务应用.....	18
七、结论与展望.....	19
7.1 研究结论.....	19
7.2 研究局限性.....	20
7.3 未来展望.....	20

摘要：针对当前二手车行业定价不规范、人工估价效率低、价格影响因子难以量化、车源分级体系混乱等行业痛点，本文以 2005 年后二手车交易数据集为研究对象，依托大数据挖掘与机器学习技术，开展二手车价格预测与车源分级研究。研究通过缺失值处理、极端值截断、特征工程、特征编码等全流程数据预处理工作，构建高质量建模数据集；分别构建线性回归与集成学习多类预测模型，通过 5 折交叉验证与多维度评价指标完成模型对比筛选，确定梯度提升回归为最优预测模型，其测试集决定系数 R^2 达 0.876，预测精度显著优于传统线性模型。同时基于 K-means 聚类算法实现二手车四档标准化分级，并量化各特征对车辆价格的影响权重。研究结果有效解决了二手车交易定价不客观、分级不标准的行业问题，可为二手车商户定价、库存管理、精准营销提供数据支撑与技术参考。

关键词：大数据挖掘；机器学习；二手车价格预测；特征分析；K-means 聚类

一、绪论

1.1 行业研究背景

随着国内汽车产业的持续发展与消费观念的升级，二手车交易市场规模逐年扩张，已成为汽车产业体系中不可或缺的核心板块。但当前二手车行业整体发展仍不够成熟，交易流程与定价体系存在诸多短板，严重制约行业规范化、智能化发展。

目前行业核心痛点集中在四个维度。其一，交易信息不对称问题突出，买卖双方、二手车商户之间掌握的车况、市场行情信息差异较大，行业缺乏统一、客观的定价参考依据，交易纠纷频发。其二，传统定价模式效率低下，估价工作高度依赖从业人员个人经验，人工评估流程繁琐、标准不统一，无法适配当下海量车源批量估价的业务需求。其三，价格影响因素繁杂，车龄、行驶里程、品牌、车型、汽缸数等多项特征相互交织，人工难以精准量化各因素对二手车价格的影响权重，定价主观性较强。其四，车辆分级体系混乱，行业暂无科学标准化的车辆等级划分规则，不利于车商开展库存优化、差异化定价与精准营销工作。

基于上述行业现状，依托大数据挖掘与机器学习技术搭建智能化二手车价格预测系统，实现自动估价、因子量化、车源分级，成为破解行业痛点、推动行业升级的有效路径。

1.2 研究核心问题

本文属于有监督回归预测与无监督聚类相结合的综合型数据挖掘研究，核心围绕三大任务展开。第一，二手车价格回归预测任务，基于车辆多维特征构建机器学习模型，实现二手车交易价格的精准预测；第二，车源聚类分级任务，依托核心车辆特征完成车辆等级标准化划分；第三，特征影响分析任务，量化各类特征对二手车价格的影响权重，挖掘数据内在关联规律。

1.3 数据基础与研究难点

本文研究采用 cleanData_2005plus.csv 数据集，包含 2005 年之后的二手车有效交易样本 5263 条，覆盖 31 个主流汽车品牌、2000 余款车型，样本覆盖面广，贴合真实二手车市场结构。数据集变量分为三类，分别为目标变量二手车交易价格、车龄、行驶里程等数值特征，以及品牌、车型、车况等分类特征。

研究过程存在四大核心难点：一是原始数据集存在 5.2% 的缺失值，主要分布在各类分类特征中，易干扰模型训练效果；二是价格、行驶里程字段存在大量极端异常值，易导致模型偏差、降低泛化能力；三是生产年份与车龄特征高度负相关，存在严重多重

共线性问题；四是分类特征数量多、类别繁杂，文本格式数据无法直接用于模型训练，需完成标准化数值编码。

1.4 研究内容与预期成果

1.4.1 主要研究内容

本文首先完成全流程数据预处理工作，通过缺失值处理、极端值过滤、特征衍生、冗余特征剔除、分类特征编码构建高质量数据集；其次搭建线性回归、集成学习多类预测模型，通过对照实验与多指标评估筛选最优模型；再次基于最优模型完成特征重要性分析，结合统计检验挖掘价格影响规律；最后通过 K-means 聚类实现车辆分级，挖掘业务应用价值，并总结模型局限性与未来优化方向。

1.4.2 预期研究成果

构建预测精度优于传统人工估价的二手车价格预测模型，量化各类特征的价格影响权重，形成标准化特征分析体系；建立四档二手车分级标准，支撑二手车行业库存管理与差异化营销；形成完整可复现的实验流程与技术方案，为模型落地部署与迭代优化提供依据。

二、数据预处理

2.1 缺失值处理

原始数据集整体缺失率为 5.2%，缺失数据集中分布在车况、燃料类型、变速箱等分类特征中，无核心字段集中缺失问题。为保障数据纯净度与模型训练效果，本文采用直接删除法剔除所有含缺失值的异常记录，处理后数据集基线稳定，满足后续建模分析要求。

2.2 极端值处理

二手车交易价格与行驶里程字段存在大量极端异常样本，超高价格、超远里程的特例数据会增大模型预测误差、降低稳定性。本文采用 1%-99% 百分位数截断法，对两类核心字段进行极端值过滤，共计删除异常样本 200 条，占总样本的 3.8%。处理后数据分布趋于平滑，有效消除了极端数据对模型训练的干扰。


2.3 特征工程与冗余剔除

为解决多重共线性问题、优化特征体系，本文开展特征衍生与冗余特征剔除工作。首先基于车辆生产年份衍生车龄特征，计算公式为 $age=2021-year$ ；其次由于生产年份

与车龄相关系数接近-1，存在完全冗余问题，直接删除生产年份字段，彻底消除多重共线性。最终保留车龄、里程、品牌、车型等九大核心特征用于模型训练。

2.4 分类特征编码

机器学习模型仅支持数值型数据输入，本文数据集包含品牌、车型、车况等 7 类文本型分类特征。研究统一采用 LabelEncoder 编码方式，将文本分类标签逐一映射为连续整数，完成所有分类特征的数值化转换，确保数据可直接用于模型训练。



```
54 # Step 2: 连续变量 + 品牌
55 X_step2 = sm.add_constant(pd.concat([X_continuous, brand_dummies], axis=1))
56
57 # Step 3: 连续变量 + 品牌 + 车型
58 X_step3 = sm.add_constant(pd.concat([X_continuous, brand_dummies, model_dummies], axis=1))
59
60 # 4.3 处理缺失值 (statsmodels 需要，但不修改原始数据，只删除建模所需行)
61 # 注意，这里的 dropna() 只是为了让模型能运行，不代表数据清洗
62 mask_step1 = X_step1.notna().all(axis=1) & df_model['price'].notna()
63 mask_step2 = X_step2.notna().all(axis=1) & df_model['price'].notna()
64 mask_step3 = X_step3.notna().all(axis=1) & df_model['price'].notna()
65
66 y = df_model['price']
67
68 # 4.4 拟合三个模型
69 print("\n" + "="*70)
70 print("Step 1: 基准模型 (odometer + age)")
71 print("="*70)
72 model1 = sm.OLS(y[mask_step1], X_step1[mask_step1]).fit()
73 print(model1.summary())
74
75 print("\n" + "="*70)
76 print("Step 2: 加入品牌虚拟变量")
77 print("="*70)
78 model2 = sm.OLS(y[mask_step2], X_step2[mask_step2]).fit()
79 print(model2.summary())
80
81 print("\n" + "="*70)
82 print("Step 3: 完整模型 (odometer + age + 品牌 + 车型)")
```

2.5 数据集划分与质量复检

为保证实验结果可复现、评估客观，按照 75%、25%的比例分层随机划分训练集与测试集，固定随机种子为 42，规避随机划分带来的结果波动。预处理完成后，从数据完整性、异常值、编码合规性、多重共线性四个维度完成全维度复检，确认数据集无缺失值、无极端异常数据、编码规范、无强共线性问题，完全满足建模与分析需求。

三、数据探索性分析

3.1 描述性统计分析

对价格、车龄、里程三大核心连续特征开展描述性统计，结果显示：样本二手车平均交易价格为 18850 美元，价格区间为 200-75000 美元，跨度覆盖低端至高端车型；平均车龄 7.6 年，区间分布 1-16 年，新旧车辆样本分布均衡；平均行驶里程 76000 英里，整体车辆使用强度处于行业正常区间，贴合真实二手车市场特征。

3.2 数据分布与异常值分析

价格整体呈右偏分布，低价车源居多、高价精品车较少，符合市场普遍规律，经极值截断后尾部异常样本被剔除，数据分布更加平滑；车龄分布相对对称，样本主要集中在 5-10 年区间；里程数据集中在 40000-100000 英里区间，超高里程异常样本已全部过滤。预处理后数据集无无效异常值，数据质量优良。




图 1 车龄、里程分布与价格相关性分析

3.3 变量相关性分析

基于皮尔逊相关系数开展相关性分析，核心结论如下：车龄、里程与二手车价格呈中等负相关，相关系数分别约为-0.4、-0.35，车辆使用损耗越大，价格残值越低；汽缸数与价格呈中等正相关，相关系数约为 0.3，动力配置越高，车辆定价越高；生产年份与车龄极强负相关，再次验证剔除生产年份特征的合理性；其余分类特征与价格线性相关性较弱，需依靠非线性模型挖掘潜在关联。




图 2 变量相关性热力图

3.4 特征分组差异分析

结合 ANOVA 方差分析对分类特征开展分组对比，结果显示各类分组价格差异极其显著 ($p < 0.001$)。8 缸车辆均价 30507 美元，较 4 缸车辆溢价 101%；卡车、皮卡车型均价 28900 美元，较普通轿车溢价 75%；豪华品牌车辆较普通品牌溢价 9.3%，同梯队品牌 Ford 相较 Toyota 均价高出 7.5%，证明车型、汽缸数、品牌是影响二手车价格的核心特征。

3.5 探索性分析总结

预处理后数据集分布合理、质量达标，可满足建模需求；车辆核心特征与价格的线性规律清晰，同时数据存在大量非线性关联关系，传统线性模型拟合效果有限，集成学习非线性模型更适配本次研究场景，为后续模型构建与特征分析奠定了数据基础。

四、模型构建与实验设计

4.1 建模整体方案

本文以二手车价格预测为核心任务，综合预测精度、泛化能力、运行稳定性三大维度开展模型构建，选取决定系数 R^2 、均方误差 MSE、均方根误差 RMSE、平均绝对误差 MAE 为核心评估指标，统一采用 5 折交叉验证提升实验可靠性。建模思路以 Lasso、Ridge 等线性回归模型为基准模型，以随机森林、梯度提升回归为核心优化模型，通过横向对比筛选最优模型。所有模型实验均采用统一数据集、统一划分比例与随机种子，保障实验公平性与可复现性。

4.2 对照实验设计

为量化数据预处理的实际优化效果，本文设置两组对照实验。对照组采用原始未处理数据，保留冗余特征、不做极端值过滤；实验组采用经过缺失值删除、极端值截断、特征优化后的高质量数据集。两组均训练 Lasso 回归模型，通过指标差异验证预处理的

4.3 基准线性模型构建

选取 Lasso 回归、Ridge 回归、ElasticNet 三类经典正则化线性回归模型作为基准模型。线性模型具备运算速度快、可解释性强的优势，但难以捕捉数据非线性关联。三类模型均采用默认参数与 5 折交叉验证训练，用于构建实验性能基线，为后续非线性模型提供对比参考。




图 4 岭回归预测效果与残差分布




图 3 Lasso 回归预测效果与残差分布

4.4 集成学习模型构建

针对数据集非线性特征显著的特点，引入两类集成学习模型。随机森林回归基于多决策树集成投票，抗干扰能力强、泛化效果优异；梯度提升回归采用迭代误差修正机制，非线性拟合能力突出，经多轮参数调优后确定最优参数：集成树数量 200、决策树最大深度 10、学习率 0.1、随机种子 42，作为本文重点优化的核心模型。




图 6 梯度提升回归预测效果、残差分布与特征重要性




图 5 随机森林回归预测效果、残差分布与特征重要性

五、模型评估与对比分析

5.1 核心评估指标释义

R^2 决定系数取值介于 0-1 之间，数值越接近 1，模型对数据的解释能力越强、拟合效果越好；MSE 均方误差可放大大误差影响，反映模型整体偏差；RMSE 均方根误差量纲与车辆价格一致，是最直观的误差评价指标；MAE 平均绝对误差对极端值鲁棒性更强，可客观反映模型平均预测偏差。

5.2 多模型性能分项评估

各模型基于优化后数据集的测试集性能指标如下：梯度提升回归 $R^2=0.876$ ，RMSE=4313 美元，MAE=3050 美元，拟合效果最优，仅存在轻微过拟合，泛化能力良好；随机森林回归 $R^2=0.852$ ，综合性能仅次于梯度提升回归；Lasso、Ridge、ElasticNet 三类线性模型 R^2 集中在 0.63-0.65 区间，RMSE 均超 7200 美元，因无法捕捉非线性关联，预测精度显著偏低。




图 8 最优模型残差分布分析




图 7 最优模型实际价格与预测价格对比

5.3 模型综合对比分析

从模型梯队来看，集成学习模型性能显著优于传统线性模型。梯度提升回归相较于基准 Lasso 回归， R^2 提升 34.6%，RMSE 下降 40.3%，MAE 下降 43.2%，各项性能指标大幅优化，充分证明非线性集成模型更适配二手车价格预测场景，最终确定梯度提升回归为最优预测模型。




图 9 多模型性能综合对比

5.4 预处理效果验证

基于 Lasso 回归开展对照实验，结果显示经极端值处理与特征优化后，模型 R^2 从 0.58 提升至 0.65，RMSE、MAE 分别下降 15%、13%。证明科学的数据预处理可有效降低数据噪声，显著提升模型预测精度与运行稳定性，是高精度建模的重要基础。

六、特征分析与聚类应用

6.1 特征重要性分析

基于最优梯度提升回归模型量化各特征影响权重，结果显示：车型重要性得分 0.385，是影响二手车价格的核心因素；车龄、里程得分分别为 0.245、0.189，位列第二、三位；三大核心特征累计重要性达 81.9%，主导二手车定价。汽缸数、品牌具备中等影响，车况对价格的影响权重最低。




图 10 特征重要性与影响方向分析

6.2 关键特征深度分析

结合统计检验结果可知，汽缸数作为车辆核心硬件配置，直接决定动力水平，高低配置车型价格差距翻倍；车辆功能定位差异形成显著溢价，商用皮卡、卡车车型价值远高于普通轿车；品牌附加值形成稳定价格分层，豪华品牌与普通品牌、同梯队不同品牌间均存在固定价格差异。

6.3 K-means 聚类模型构建

以价格、车龄、里程为核心特征，经 Z-Score 标准化消除量纲影响后，结合肘部法则与轮廓系数确定最优聚类数 k=4。模型最终轮廓系数为 0.276，Calinski-Harabasz 指数为 3877，聚类样本边界清晰、类内聚合度高，聚类效果良好。

6.4 聚类结果与业务应用

聚类将二手车划分为四类等级：高端车车龄短、里程低、价格最高，为精品准新车；中端车参数均衡，是市场主流交易车型；经济型车里程偏高、价格亲民，主打高性价比；老旧车车龄与里程偏高，车辆残值较低。该四档分级体系可实现标准化价格分级、优化车商库存管理、支撑差异化精准营销，具备极高的落地应用价值。




图 11 K-means 聚类结果可视化与特征对比

七、结论与展望

7.1 研究结论

本文基于大数据挖掘与机器学习技术，完成二手车价格预测与车源分级全流程研究，得出以下核心结论。第一，科学的数据预处理可有效解决数据缺失、异常、共线性等问题，大幅提升模型预测性能，是高精度建模的核心前提。第二，非线性集成学习模型适配二手车价格预测场景，梯度提升回归模型预测精度最优，可解释 87.6% 的价格波动，能够满足智能化估价需求。第三，车型、车龄、行驶里程是影响二手车价格的三大核心因素，累计影响权重超 80%，汽缸数、品牌等特征形成辅助价格分层。第四，基于 K-means 算法构建的四档车辆分级体系科学有效，可完美适配二手车行业库存管理、定价营销等业务场景。

7.2 研究局限性

本次研究仍存在诸多不足。数据层面，数据集未纳入车辆事故记录、保养情况、交易地区、内饰配置等高价值特征，特征维度不够全面；分类特征仅采用简单数值编码，存在少量信息损失。模型层面，最优梯度提升回归模型存在轻微过拟合问题，泛化能力仍有优化空间，且未引入时序特征，无法捕捉市场价格的动态波动规律。实验层面，仅采用单一极端值处理方式，未开展多策略对比验证。

7.3 未来展望

未来可从三个维度开展优化研究。数据层面，扩充车辆配置、事故、地域、时序等特征，优化分类特征编码方式，扩大样本数据集，进一步提升数据维度与质量。模型层面，通过正则化、参数调优缓解模型过拟合问题，尝试 XGBoost、LightGBM 等进阶算法，融合时序分析挖掘价格动态变化规律。业务层面，搭建可视化定价分析平台，开发智能分级、差异化定价、车源推荐功能，形成标准化行业解决方案，推动二手车行业全面智能化升级。